

Dokumen Project Plan

Pijak in collaboration with IBM Skillsbuild

ID Tim Capstone Project: PJK-GM091

Tema Capstone : AI for Business Intelligence and Market Insights

Nama Proyek/Product : AI-Powered Customer Segmentation & Market Insight Dashboard

List Anggota :

1. (APC367D6X0065) - (Nida Nurapipah) - **[Aktif]**
2. (APC012D6Y0079) - (Nazly Rafa Oktafian Nuzqu) - **[Aktif]**
3. (APC005D6Y0216) - (Muhammad Yusuf) - **[Aktif]**
4. (APC182D6Y0087) - (Rifki Saputra) - **Aktif**
5. (APC222D6Y0309) - (Andi Muchamad Mugni Pabilla) - **[Aktif]**

A. Ringkasan Eksekutif

1) Latar Belakang

Banyak pelaku usaha di Indonesia, terutama UMKM dan retail kecil-menengah, memiliki data transaksi pelanggan namun tidak tahu cara mengolahnya menjadi keputusan bisnis. Mereka menjalankan promosi tanpa tahu siapa pelanggan utama, mana produk paling laku per kelompok pelanggan, dan bagaimana memprediksi pelanggan yang akan kembali. Tools BI komersial mahal dan rumit, sementara tim mereka bukan data scientist.

2) Problem Statement (5W+1H).

- *What*: pelaku usaha sulit memahami pola pembelian dan mengelompokkan pelanggan secara terstruktur.
- *Why*: belum ada tools sederhana, gratis, dan dalam Bahasa Indonesia yang menggabungkan segmentasi dan insight bisnis.
- *Who*: pemilik UMKM dan staf marketing retail.
- *Where*: ekosistem retail Indonesia.
- *When*: pada setiap perencanaan promosi atau evaluasi kuartalan.
- *How*: melalui aplikasi web open-source yang mudah digunakan tanpa coding.

3) Solusi

Sistem Insight Pembelian dan Segmentasi Pasar berbasis web yang dibangun 100% dengan teknologi open-source Python. Pengguna mengunggah data transaksi dalam format CSV, lalu sistem otomatis menjalankan:

- Analisis RFM (Recency, Frequency, Monetary),
- Segmentasi pelanggan dengan K-Means,
- Klasifikasi tipe pelanggan menggunakan Random Forest,
- Rekomendasi produk top per segmen, dan
- Insight ringkas dalam Bahasa Indonesia menggunakan template berbasis aturan.

Seluruh hasil ditampilkan dalam dashboard interaktif Streamlit.

4) Research Questions.

1. Apakah segmentasi RFM + K-Means menghasilkan kelompok pelanggan yang interpretable dengan Silhouette Score $\geq 0,50$?
2. Sejauh mana model Random Forest dapat memprediksi segmen pelanggan baru berdasarkan fitur RFM?
3. Bagaimana insight berbasis aturan dapat membantu pelaku UMKM mengambil keputusan promosi sederhana per segmen?

5) Mengapa Proyek Ini adalah painkiller:

SIPASAR menjawab kebutuhan nyata pasar Indonesia dengan pendekatan minimalis: scope yang ramah pemula, teknologi 100% open-source, output yang langsung digunakan stakeholder. Proyek selaras dengan tema *AI for Business Intelligence and Market Insights*, realistis dikerjakan tim 5 orang pemula dalam waktu 3 minggu efektif, dan menghasilkan aplikasi web yang dapat di-deploy gratis serta menjadi portofolio kuat tiap anggota.

B. Cakupan Proyek dan Hasil Kerja

In-Scope (akan dikerjakan)

- ☒ Data preprocessing & cleaning dataset retail publik (Online Retail UCI – **1 dataset saja**).
- ☒ Feature engineering RFM (Recency, Frequency, Monetary).
- ☒ **Modul 1 – Segmentation:** K-Means clustering (algoritma tunggal) + evaluasi Silhouette Score & Elbow Method.
- ☒ **Modul 2 – Classification:** Random Forest (algoritma tunggal) untuk memprediksi segmen pelanggan baru.

- ☑ **Modul 3 – Top Product per Segment:** ranking produk paling laku per segmen (group-by + count).
- ☑ **Modul 4 – Insight Generator:** rule-based template Bahasa Indonesia (if-else sederhana per segmen).
- ☑ **Aplikasi Web:** dibangun dengan **Streamlit** (single-file, no separate frontend/backend).
- ☑ **Deployment:** Streamlit Community Cloud (1-click deploy, gratis).
- ☑ **Dokumentasi:** README, User Guide singkat, Final Report PDF, Video Demo ≤5 menit.

Out-of-Scope (TIDAK dikerjakan)

- ✗ DBSCAN, Hierarchical Clustering, dan algoritma clustering lain.
- ✗ XGBoost, Logistic Regression, dan algoritma klasifikasi lain.
- ✗ Collaborative Filtering, SVD, Matrix Factorization.
- ✗ Forecasting (ARIMA, Prophet, LSTM).
- ✗ Deep Learning / TensorFlow di pipeline produksi.
- ✗ FastAPI, frontend HTML/CSS/JS terpisah, Backend microservice.
- ✗ Mobile app, authentication, payment, real-time streaming.
- ✗ API AI eksternal (LLM, watsonx, OpenAI, Hugging Face Inference API).
- ✗ Database server (cukup CSV/SQLite lokal).

C. Jadwal Pengerjaan

Minggu	Milestone	Tugas	Output
Minggu 1	Persiapan & Preprocessing	- Eksplorasi Dataset (EDA) - Data cleaning & handling missing values - Pembuatan fitur	Dataset siap pakai & Analisis awal

		RFM (Recency, Frequency, Monetary) .	
Minggu 2	Modeling (Segmen & Klasifikasi)	- Clustering K-Means (Elbow & Silhouette) - Training Model Random Forest	Model .pkl / .sav & Evaluasi performa
Minggu 3	Analisis & Sistem Insight	- Analisis produk terlaris per segmen - Pembuatan rule-based template (Bahasa Indonesia)	Logika sistem & Insight bisnis
Minggu 4	Deployment & Dokumentasi	- Pembuatan UI dengan Streamlit - Deployment ke Streamlit Community Cloud - Penyusunan README & Final Report	Link Web App & Dokumen Final

D. Uraian Rencana Penugasan/*Job Desk* Setiap Learning Path

Tim terdiri dari 5 anggota, pembagian tugas difokuskan pada pengembangan pipeline data dari preprocessing hingga deployment.

Pembagian Tanggung Jawab Tim

Karena seluruh anggota tim berasal dari learning path yang sama, pembagian akan fokus pada kombinasi kemampuan masing masing:

ROLE	ANGGOTA	TANGGUNG JAWAB	DELIVERABLES
Data Preparation & Documentation Lead	Nida Nurapipah	Mengumpulkan dataset Online Retail UCI, memahami struktur data, membersihkan missing value, duplikasi, transaksi batal, quantity/price tidak valid, serta mendokumentasikan proses cleaning.	Dataset bersih CSV, notebook preprocessing, dokumentasi dataset.
EDA & Business Analytics Lead	Rifki Saputra	Melakukan exploratory data analysis, membuat visualisasi pola transaksi, produk terlaris, customer value, distribusi RFM, serta merumuskan insight bisnis awal.	Notebook EDA, grafik analisis, ringkasan insight awal, kontribusi laporan analisis.
Clustering Model Lead	Nazly Rafa Oktafian Nuzqu	Membuat fitur RFM, melakukan scaling, membangun model K-Means, menentukan jumlah cluster optimal menggunakan Elbow Method dan Silhouette Score, serta memberi interpretasi label segmen.	Model K-Means .pk1 , hasil Elbow Method, Silhouette Score, tabel segmentasi pelanggan.
Classification & Insight Generator Lead	Muhammad Yusuf	Membangun model Random Forest untuk memprediksi segmen pelanggan baru, mengevaluasi performa model, membuat rule-based insight generator, dan	Model Random Forest .pk1 , classification report, modul insight generator Python,

		membuat rekomendasi sederhana per segmen.	rekomendasi promosi per segmen.
Dashboard & Deployment Lead	Andi Muchamad Mugni Pabilla	Membangun aplikasi Streamlit, membuat fitur upload CSV, menampilkan visualisasi segmentasi, top product per segment, insight otomatis, serta melakukan deployment ke Streamlit Community Cloud.	Source code dashboard, GitHub repository public, aplikasi Streamlit live, README, user guide.

Data Preparation & Documentation Lead

Area fokus : Data Engineering & Quality Assurance

Tanggung Jawab:

1. Data Cleaning : Mengumpulkan dataset Online Retail UCI dan membersihkan data dari missing values, transaksi batal (quantity negatif), dan unit price nol.
2. Feature Engineering : Melakukan transformasi data mentah menjadi fitur RFM (Recency, Frequency, Monetary) yang siap digunakan untuk pemodelan.
3. Dokumentasi Teknis : Menyusun laporan awal proses preprocessing dan memastikan dataset siap pakai tersedia untuk anggota tim lain.

Indikator Target Keberhasilan :

- Dataset bersih tanpa duplikasi dan nilai tidak valid.
- Tersedianya file data fitur RFM yang terstandarisasi.

EDA & Business Analytics Lead

Area fokus: Exploratory Data Analysis & Business Intelligence

Tanggung Jawab:

1. Eksplorasi Data (EDA): Melakukan analisis mendalam terhadap pola transaksi awal sebelum dilakukan clustering.
2. Market Insight: Mengidentifikasi tren penjualan dan distribusi nilai transaksi untuk memberikan konteks bisnis pada hasil segmentasi.
3. Visualisasi Analitik: Menyiapkan grafik distribusi RFM sebagai landasan interpretasi segmen pelanggan.

Indikator Target Keberhasilan:

- Teridentifikasinya pola pembelian utama dalam dataset.
- Visualisasi awal yang mendukung validasi fitur RFM.

Clustering Model Lead

Area fokus : Unsupervised Learning (Modul 1)

Tanggung Jawab:

1. Pemodelan K-Means: Membangun model clustering K-Means dan menentukan jumlah kelompok optimal menggunakan *Elbow Method* dan *Silhouette Score*.
2. Evaluasi Model: Memastikan model mencapai target Silhouette Score $\geq 0,50$ atau memberikan interpretasi bisnis jika skor di bawah target.
3. Eksport Model: Menyimpan hasil clustering terbaik dalam format file **.pk1** atau **.sav**.

Indikator Target Keberhasilan :

- Terbentuknya segmen pelanggan yang terukur dan *interpretable*.
- File model clustering siap digunakan di pipeline dashboard.

Classification & Insight Generator Lead

Area fokus : Supervised Learning (Modul 2 & 4)

Tanggung Jawab:

1. Model Klasifikasi: Melatih model *Random Forest* untuk memprediksi label segmen pelanggan baru berdasarkan fitur RFM yang telah ada.
2. Insight Generator: Membangun sistem *rule-based template* dalam Bahasa Indonesia (menggunakan logika *if-else*) untuk memberikan rekomendasi strategi bisnis per segmen.
3. Analisis Produk: Melakukan perankingan produk paling laku (*top products*) per kelompok pelanggan.

Indikator Target Keberhasilan:

- Model Random Forest memiliki akurasi yang baik dalam klasifikasi segmen.
- Tersedianya modul logika insight yang informatif bagi pelaku UMKM.

Dashboard & Deployment Lead

Area fokus : Web Development & Cloud Infrastructure

Tanggung Jawab:

1. UI/UX Dashboard: Membangun antarmuka dashboard interaktif menggunakan Streamlit yang mencakup fitur unggah CSV dan tampilan visualisasi.
2. Integrasi & Caching: Mengintegrasikan model `.pk1` ke dalam UI dan menerapkan `@st.cache_data` untuk memastikan aplikasi berjalan cepat.
3. Deployment: Melakukan publikasi aplikasi ke *Streamlit Community Cloud* dan memastikan stabilitas akses web app.

Indikator Target keberhasilan:

- ❖ Aplikasi dapat diakses melalui link publik tanpa error saat memuat model.
- ❖ Antarmuka yang ramah pengguna bagi pemilik UMKM.

E. Sumber Daya Proyek

Tim terdiri dari 5 anggota dengan pembagian peran sebagai berikut:

- 1 Data Preparation & Documentation Lead
- 1 EDA & Business Analytics Lead
- 1 Clustering Model Lead
- 1 Classification & Insight Generator Lead
- 1 Dashboard & Deployment Lead

Total alokasi waktu: 4 minggu

Sumber Daya Teknologi

Development Tools:

- IDE: Visual Studio Code
- Data Processing: Google Colab / Jupyter Notebook
- Version Control: Git + GitHub
- Project Management: GitHub Projects
- Communication: Discord and Google Meets
- Documentation: Google Docs

Tech Stack:

- Frontend dan Backend Serta deployment : Streamlit

- Dataset kaggle

Sumber Daya Eksternal

Learning Resources:

- Dokumentasi resmi Python, FastApi
- Stack Overflow dan ChatGPT
- GitHub repositories sebagai referensi

Mentoring:

- Clinic session dengan use case owner (PIC Dicoding)
- Konsultasi dengan mentor Dicoding
- Code review dari senior developers

F. Rencana Manajemen Risiko dan Isu

1. Risiko Teknis

Risiko	Probabilitas	Dampak	Strategi Mitigasi	Rencana Kontinjensi
Dataset memiliki missing value, duplikasi, atau transaksi tidak valid	Tinggi	Sedang	Melakukan data cleaning dengan menghapus CustomerID kosong, quantity negatif, unit price nol, dan transaksi batal.	Jika data terlalu kotor, gunakan subset data yang sudah bersih dan terdokumen tasi.
Silhouette Score	Sedang	Tinggi	Melakukan scaling data,	Jika skor tetap

K-Means kurang dari target 0,50			mencoba beberapa nilai K, dan mengevaluasi ulang fitur RFM.	rendah, gunakan interpretasi bisnis sebagai pendukung dan jelaskan keterbatasan model.
Model Random Forest memiliki akurasi rendah	Sedang	Sedang	Melakukan train-test split yang tepat, balancing label jika diperlukan, dan tuning parameter sederhana.	Jika akurasi rendah, gunakan model hanya sebagai fitur prediksi tambahan, bukan fitur utama.
File model .pkl gagal di-load di Streamlit	Sedang	Sedang	Menyamakan versi library, menyimpan model dengan joblib/pickle, dan melakukan testing lokal sebelum deploy.	Jika gagal, jalankan proses training langsung di aplikasi dengan dataset kecil.
Deployment Streamlit gagal	Sedang	Tinggi	Menyiapkan requirements.txt , memastikan	Jika Streamlit Cloud gagal, tampilkan

			path file benar, dan testing aplikasi secara lokal.	demo lokal melalui screen recording.
--	--	--	---	--------------------------------------

2. Risiko Manajemen Proyek

Risiko	Probabilitas	Dampak	Strategi Mitigasi	Rencana Kontinjensi
Kualitas data rendah (banyak data kosong/duplikat)	Tinggi	Tinggi	Melakukan Exploratory Data Analysis (EDA) secara mendalam di awal minggu pertama.	Menggunakan teknik imputation atau menghapus fitur yang memiliki missing value di atas 50%.
Keterlambatan pengerjaan (melebihi 4 minggu)	Sedang	Tinggi	Membuat <i>timeline</i> mingguan yang ketat dan membagi tugas secara paralel.	Menyederhanakan fitur aplikasi (fokus pada MVP - <i>Minimum Viable Product</i>).
Model Overfitting	Sedang	Tinggi	Menggunakan teknik Cross-Validation dan	Mengganti algoritma klasifikasi (misal: dari

			Hyperparameter Tuning.	Random Forest ke XGBoost).
--	--	--	------------------------	----------------------------

3. Risiko Pengalaman Pengguna

Risiko	Probabilitas	Dampak	Strategi Mitigasi	Rencana Kontinjensi
Aplikasi Lambat	Tinggi	Sedang	Menggunakan fungsi <code>@st.cache_data</code> pada Streamlit untuk menyimpan proses komputasi.	Membatasi jumlah baris data yang bisa diunggah/di proses dalam satu waktu.
Antarmuka (UI) Membingungkan	Sedang	Sedang	Melakukan user testing kecil ke teman sejawat sebelum deployment final.	Menambahkan instruksi penggunaan (Panduan/Help) di <i>sidebar</i> aplikasi.
Output Analisis Sulit Dipahami	Rendah	Tinggi	Menyertakan visualisasi (grafik) dan penjelasan sederhana untuk setiap segmen pelanggan.	Menyediakan fitur unduh (Download Report) dalam format CSV agar pengguna

				bisa cek manual.
--	--	--	--	------------------

4. Analisis SWOT

Analisis SWOT (*Strengths, Weaknesses, Opportunities, dan Threats*) dilakukan untuk mengevaluasi posisi proyek dalam ekosistem solusi analisis data saat ini. Melalui analisis ini, tim dapat memetakan faktor internal yang menjadi kekuatan pendukung dan kelemahan yang perlu dimitigasi, serta faktor eksternal berupa peluang pengembangan di masa depan dan ancaman yang mungkin menghambat keberhasilan proyek.

Tujuan utama dari analisis ini adalah untuk memastikan bahwa solusi segmentasi pelanggan yang dikembangkan tidak hanya unggul secara teknis, tetapi juga relevan dengan kebutuhan pasar (khususnya UMKM di Indonesia) dan memiliki rencana keberlanjutan yang matang.

